

RETHINKING MACHINE UNLEARNING FOR LARGE LANGUAGE MODELS

Michigan State University, IBM, ByteDance, MIT
2024.07.15

Content

1. Introduction
2. Related Work
3. Unpacking LLM Unlearning
4. Current Unlearning Techniques and Overlooked Principles
5. Assessing LLM Unlearning
6. Applications of LLM Unlearning
7. Challenges and Overlook

Introduction

- 최근 LLM이 powerful한 성능을 보여주지만, **extensive corpora**를 학습한 LLM은 윤리적 혹은 안전 문제를 야기할 수 있어 pretrained LLM을 다양한 safety context를 위해 **tailor**할 필요가 있음.
- 이미 사전학습된 모델을 undesirable data를 없애기 위해 재학습 키시는 것은 매우 비효율적이며 **Machine Unlearning (MU)**가 한 가지 방법이 될 수 있음.
 - 여태까지 Classification tasks와 관련되어 MU가 연구되어 왔는데, 본 연구에서 LLM Unlearning에 대해 깊은 분석과 함께 개념을 정리해보고자 함.

Introduction

- 아래 figure에서 보이는 바와 같이 LLM unlearning의 landscape을 정의함

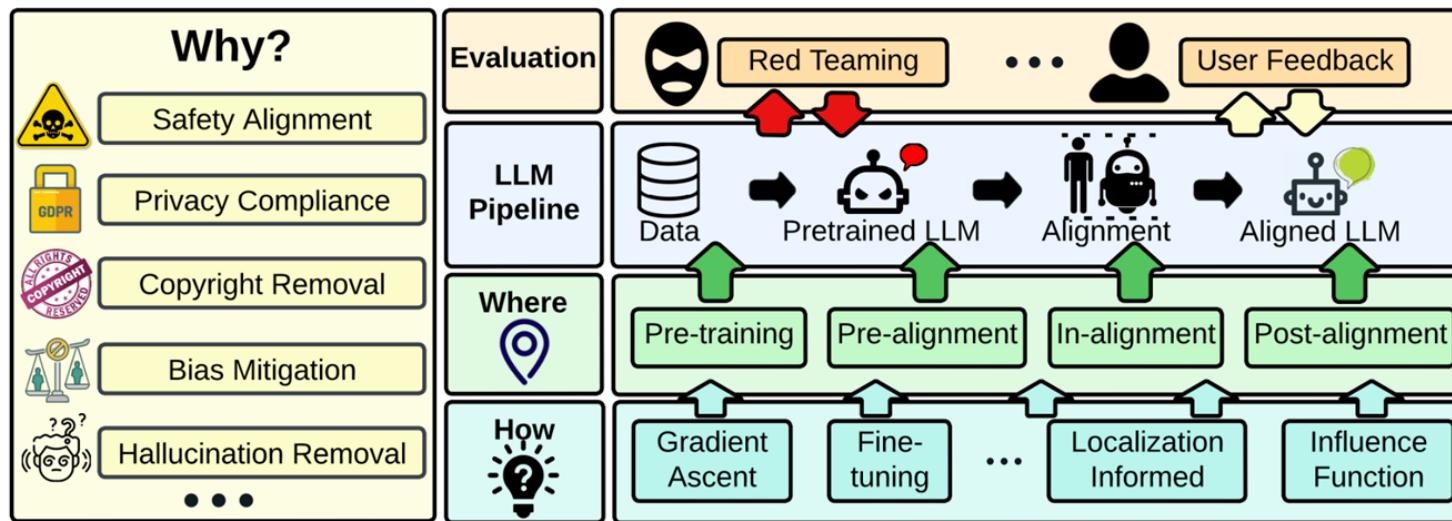


Figure 1: Demonstration of how MU can be incorporated into LLM development cycle. The landscape of LLM unlearning will be mainly navigated from applications ('why'), methods ('where' and 'how'), and evaluations.

Related Work

MU for non-LLMs

- Machine Unlearning 연구는 '*the right to be forgotten*'과 같이 data protection regulation을 위해 소개됨
 - 모델 성능에 대한 Data Influence를 평가하는 것이기에, 다양한 영역에서 MU가 연구됨.
 - Image classification, Text-to-image generation, federated learning, graph neural networks, recommendation
- '**Exact**' unlearning은 말 그대로 특정 training data points를 제거한 후에 model을 다시 학습시키는 것이 standard이지만, 이 방법은 많은 연산량과 전체 training data가 필요하기 때문에 **적용하기가 어려움**.
 - 따라서, **scalable한 approximate unlearning** 방법들이 많이 연구 개발 되옴.

Related Work

Challenge of MU for LLMs

LLM Unlearning은 새로운 challenges들과 complexities를 소개함

1. 대량의 text data로 학습된 LLMs은 **unintentional bias**을 갖거나 **confidential information**을 저장할 수 있음. → ‘unlearning targets’을 정확하게 define하는 것이 중요함.
 - 최근에 LLM Unlearning 연구는 주로 context and task-dependent하게 이루어지는 반면에 LLM Unlearning을 위한 표준화된 corpora가 별도로 없음.
1. LLM 크기가 커지고 black-box access와 같은 LLM-as-a-service 때문에 **MU techniques**을 LLM에 바로 적용하기에는 어려움
 - 이러한 challenges들을 해결하기 위해 black-box models에도 적용할 수 있는 in-context unlearning([Pawelczyk et al., 2023](#))과 retraining을 간소화 하기 위해 synthetic data를 학습에 사용하는 fictitious unlearning([Maini et al., 2024](#))가 소개됨.
1. LLM에서 unlearning의 **scope**는 명확하게 정의되지 않음 (model editing과 유사한 문제)
 - 효과적인 Unlearning은 LLMs의 predefined scope에서 targeted data의 knowledge는 지우고 동시에 outside of scope에 대한 knowledge는 유지되어야 하는데, 이전 연구들은 ‘무엇을 기억하고 무엇을 잊을지에 대해 명확하게 정의하지 않음
1. 다양한 applications에 있어 LLM unlearning에 대한 needs가 있지만, 아직까지는 **comprehensive/reliable evaluation 기준이 마련되지 않음**
 - 최근 연구에서는([Patil et al., 2024](#), [Lynch et al., 2024](#), [Zhang et al., 2024a](#)) sensitive information이 LLM post-unlearning (target=sensitive information) 이후에도 **reverse-engineered**될 수 있다고 하는데, 이것은 철저한 **adversarial evaluation**과 **unlearning**이 잘 되었음을 보장하는 것에 대한 설계 방법이 필요하다는 것을 시사함

Unpacking LLM Unlearning

- 저자들은 다음과 같이 LLM unlearning을 정의함

(LLM unlearning) *How can we efficiently and effectively eliminate the influence of specific ‘unlearning targets’ and remove associated model capabilities while preserving model performance for non-targets?*

- 위에 Statement를 4가지 관점에서 해석함.
 - Unlearning Targets
 - Influence Erasure
 - Unlearning Effectiveness
 - Efficiency

Unpacking LLM Unlearning

1. **Unlearning targets:** unlearning tasks들은 다양한 형태로 정의될 수 있음.
 - a. 가령, *data influence removal*이나 *model capability removal*이 될 수 있음. 전자는 주로 IP 보호가 될 수 있고, 후자는 AI alignment 및 safety가 될 수 있음.
2. **Influence erasure:** LLM unlearning을 달성하기 위해서는 data와 model을 공동으로 검토해야함.
 - a. 완전한 Influence erasure의 목표는 unlearning된 모델의 robustness와 generalization을 내포함. 특히 최근 approximation 방법에 관한 연구에 따르면 jailbreaking이나 post-unlearning으로 forgotten information이 재생성될 수 있음. → robustness와 generalization이 필요함을 시사
3. **Unlearning effectiveness:** LLM unlearning의 효과는 특정 data에 대한 영향을 지우는 것 말고도 더 큼.
 - a. Unlearning scope는 in-scope examples들에 대한 influence erasure의 accuracy를 의미하고, out-of-scope examples들에 대한 generation consistency는 유지하는 것을 의미함.
 - b. in-scope와 out-of-scope의 경계를 나누는 것은 특정 개념이 논리적으로 다른 것에 영향을 어떻게 끼치는지 모르기 때문에 어렵다 (*knowledge entanglement*).
4. **Unlearning efficiency & feasibility:**
 - a. 대부분 approximate unlearning 방법들이 retraining from scratch보다 저렴하지만, 수백 billion에 달하는 LLM들에 적용하는 것은 여전히 많은 cost를 야기함.
 - b. 또한 black-box LLM들은 모델과의 상호작용이 입력-출력 질의로 제한되기 때문에 unlearning을 수행하는데 어려움이 있음.

Unpacking LLM Unlearning

앞에서 정의한 4가지 기준으로 existing LLM unlearning 연구들을 다음과 같이 categorize할 수 있음

Related work	Unlearning targets/tasks	Influence erasure methods	Effectiveness: (I) In-scope evaluation for unlearning efficacy (O) Out-of-scope evaluation for model utility	Efficiency
(Lu et al., 2022)	Reducing toxic content, avoiding undesirable sentiments, and preventing repeated text generation	Reward-reinforced model fine-tuning	(I) Toxic prompts, specific sentiments, & repetitive sentences (O) Unlearning target-irrelevant prompts	N/A
(Jang et al., 2022)	Degenerating private information, w/ unlearning response irrelevant to this info	Gradient ascent-based fine-tuning	(I) Prompts from training data extraction (O) Natural language understanding tasks	Runtime cost
(Kumar et al., 2022)	Text de-classification, w/ unlearning response close to that of retraining*	Sharded, isolated, sliced, and aggregated (SISA) training via adapter	(I) No evaluation for unlearning efficacy (O) Test set	Runtime cost Memory cost
(Ilharco et al., 2022) (Zhang et al., 2023c)	Degenerating toxic content	Task vector-based parameter-efficient fine-tuning via LoRA	(I) Prompts leading to toxic generation (O) Perplexity on other datasets	N/A
(Wang et al., 2023)	Text de-classification/de-generation, unlearning specific words in translation, w/ response close to that of retraining*	KL-divergence-based fine-tuning	(I) Training subset (O) Test set	Runtime cost
(Yu et al., 2023)	Unlearning gender and profession bias, with de-biased unlearning response	Weight importance-informed & relabeling-based fine-tuning	(I) Biased prompts (O) No evaluation for model utility	N/A
(Pawelczyk et al., 2023)	Text de-classification, w/ unlearning response close to that of retraining*	In-context learning	(I) Training subset (O) Retain & test sets	Black-box access
(Eldan & Russinovich, 2023)	Degenerating Harry Potter-related book content, w/ unlearning response irrelevant to Harry Potter	Relabeling-based fine-tuning	(I) Questions and their rephrased/hard versions about Harry Potter (O) NLU tasks	N/A
(Ishibashi & Shimodaira, 2023)	Unlearning knowledge from QA dataset, with refusal response (e.g., 'I don't know')	Relabeling-based fine-tuning	(I) Adversarial and original questions about forgotten knowledge (O) Other QA prompts	N/A
(Chen & Yang, 2023)	Text de-classification and de-generation, with response close to that of retraining*	KL divergence-based parameter-efficient fine-tuning via adapter	(I) Training subset (O) Retain & test sets	Runtime cost
(Wu et al., 2023b)	Degenerating private information, w/ unlearning response irrelevant to this info	Importance-based neuron editing	(I) Memorized private data points (O) Test set	Runtime cost
(Yao et al., 2023)	Degenerating harmful prompts, degenerating Harry Potter-related book content, and reducing hallucination	Integration of gradient ascent, random labeling, & KL divergence-based fine-tuning	(I) Prompts related to unlearning targets (O) NLU tasks	Runtime cost
(Maini et al., 2024)	TOFU: Unlearning biographical knowledge about fictitious authors	Fine-tuning with various objectives	(I) Q&A about the unlearning authors (O) Q&A about other authors and general facts	Runtime cost
(Patil et al., 2024)	Degenerating sensitive information using factual information as a testbed	Model editing techniques and constrained finetuning	(I) Prompts for unlearned factual knowledge (O) Prompts for unrelated factual knowledge	White-box v. black-box access

Unpacking LLM Unlearning

앞에서 정의한 4가지 기준으로 existing LLM unlearning 연구들을 다음과 같이 categorize할 수 있음

(Thaker et al., 2024)	Harry Potter questions and author biography in TOFU (Maini et al., 2024)	Guardrailing with a separate LLM	(I) Q&A about Harry Potter and unlearning authors (O) Standard NLP benchmarks	N/A
(Zhang et al., 2024b)	Fictitious unlearning using TOFU (Maini et al., 2024)	Negative preference optimization	Same as TOFU (Maini et al., 2024)	N/A
(Li et al., 2024a)	Hazardous knowledge in the domain of biology, cybersecurity, and chemistry	Optimization towards random representations for unlearning concept	(I) Zero-shot Q&A about hazardous knowledge (O) Zero-shot Q&A about other general knowledge, and fluency of models	N/A
(Barbulescu & Triantafillou, 2024)	Specific text sequences memorized by LLM	Memorization-aware gradient ascent	(I) Memorization scores of the forget samples (O) Commonsense and scientific reasoning tasks	N/A
(Wang et al., 2024c)	Private, toxic, and copyrighted knowledge	Factual relation removal in MLP layers	(I) Accuracy of generating ground-truth knowledge (O) Evaluation on reasoning abilities	N/A
(Wang et al., 2024a)	Fictitious unlearning using TOFU (Maini et al., 2024)	Reverse KL divergence based knowledge distillation	(I) Q&A about the unlearning authors (O) Commonsense and scientific reasoning tasks	N/A
(Liu et al., 2024)	Fictitious unlearning using TOFU (Maini et al., 2024), hazardous knowledge using WMDP (Li et al., 2024a), copyrighted content in news articles and book	Detecting the forget prompts and corrupting their embedding space	(I) Q&A or completion of the unlearned knowledge (O) Eleven common LLM benchmarks	Runtime cost

Unpacking LLM Unlearning

- 저자들은 다음과 같이 LLM unlearning을 정의함

(LLM unlearning) *How can we efficiently and effectively eliminate the influence of specific ‘unlearning targets’ and remove associated model capabilities while preserving model performance for non-targets?*

- 위에 Statement를 4가지 관점에서 해석함.
 - Unlearning Targets
 - Influence Erasure
 - Unlearning Effectiveness
 - Efficiency

→ 앞에서 논의한 관점에서 보면 LLM unlearning은 종종 상황에 의존적이고 명확하게 정의되지 않은 더 광범위한 대상을 포함한다. 또한, LLM unlearning의 효과는 특정 data point의 영향을 잊는 것에만 국한되지 않고, 모델의 특정 능력 제거를 위한 더 넓은 unlearning 범위를 정의하는 것도 포함된다.

Unpacking LLM Unlearning

Mathematical modeling

아래 식은 LLM의 unlearning 과정을 mathematical modeling한 것입니다.

$$\min_{\theta} \underbrace{\mathbb{E}_{(x, y_f) \in \mathcal{D}_f} [\ell(y_f | x; \theta)]}_{\text{Forget}} + \lambda \underbrace{\mathbb{E}_{(x, y) \in \mathcal{D}_r} [\ell(y | x; \theta)]}_{\text{Retain}}$$

$$l(y | x; \theta)$$

- D_f D_r 는 x 를 입력으로 넣고 y 에 대해 prediction loss를 계산함
- y_f 은 각각 forget 집합과 retain 집합을 의미함
- λ 는 post-unlearning model의 응답을 의미함
- 는 forget과 retain의 비율을 조절하는 regularization parameter
- Forget 집합 data는 training corpus의 부분집합이 될 수 있는데, 꼭 속할 필요는 없음
 - a. unlearning을 목표로 하는 content는 특정 training sample이 아니라 더 일반적인 개념 자체를 나타내는 경우가 많기에 LLM unlearning은 특정 훈련 sample만 unlearning하는 것이 아니라, 공통된 특성을 공유하는 유사한 sample에도 일반화해야 함.

Unpacking LLM Unlearning

Model and optimization setups

- Unlearning은 주로 post-model training 단계에서 이루어지며, 일반적인 objective는 original pre-trained model을 효율적으로 update하여 D_f 에 대해서는 잊고 D_r 에 대해서는 유지하는 것이다.
- 최근 연구에 따르면 Optimizer를 선택할 때, Sophia와 같은 second-order optimization은 first-order optimization 보다 unlearning performance에 도움 됨.
- **unlearning response**에 대한 설계도 중요한데,
 - 특정 정보를 삭제하려는 *stateful LLM unlearning methods*는 unlearning response가 word 단위로 replacement를 하는 것. → **hallucination**을 야기할 수 있음
 - *empty response*로 (“I don’t know” response 혹은 unlearning 정보를 <masking>) 두는 것은 unlearning scope 내에만 있는 samples들에 대해서만 적용되도록 해야함. → 그렇지 않으면 **잦은 refusal response**가 발생할 수 있어 LLM에 대한 UX가 저하될 수 있음

Current Unlearning Techniques and Overlooked Principles

최근 LLM unlearning은 두 가지로 분류될 수 있다.

- Model-based: model의 weight을 변형하거나 architecture에 수정을 가함
- Input-based: input instruction의 design choice (in-context examples or prompts)

→ 최근 LLM Unlearning 관련 연구는 주로 **Model-based**로 이루어짐

Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- Gradient ascent (GA) and its variants
 - GA는 unlearning 방법으로 가장 직관적인 방법이 될 수 있는데, 이는 forget set D_f 에 대한 sample들의 mis-prediction에 대한 gradient를 계산하여 θ 를 업데이트하는 방식이다.
$$\mathcal{L}_{UL}(f_\theta, \mathbf{x}) = -\sum_{t=1}^T \log(p_\theta(x_t | x_{<t}))$$

$$\theta_{t+1} \leftarrow \theta_t + \lambda \nabla_{\theta_t} \ell(h_\theta(\mathbf{x}), y), \quad (x, y) \sim D$$
 - (Yao et al., 2023)에서는 LLM Unlearning에서 GA가 적합하다는 근거로 다음 내용들을 언급: Negative samples만 주어진 상황에서 유해한 text 생성을 막는데 효과적임 → RLHF에서는 pos/neg samples들이 다 필요한 반면에, GA는 유해한 token을 출력하지 않는 것이 목표이므로, 유해한 token의 gradient 반대 방향으로 model을 update하여 prob을 직접적으로 줄일 수 있음 (이때 pos label이 별도로 필요 없음) + 작은 classifier에서 발생하는 Coarseness 문제가 LLM은 모델이 크기 때문에, robust함
 - 하지만 GA는 hyperparameter tuning에 매우 sensitive하여 catastrophic collapse와 같은 unlearning failures를 야기할 수 있음
→ 이를 해결하기 위해 GA variants들이 소개됨

Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- NPO ([Zhang et al., 2024](#))
 - NPO를 쉽게 생각하면 DPO에서 positive samples을 없앤 objective function으로 해석할 수 있음
 - Gradient 과정에서 바라보면 GA에서 adaptive weighting을 하 거기 NPO로 볼 수 있으

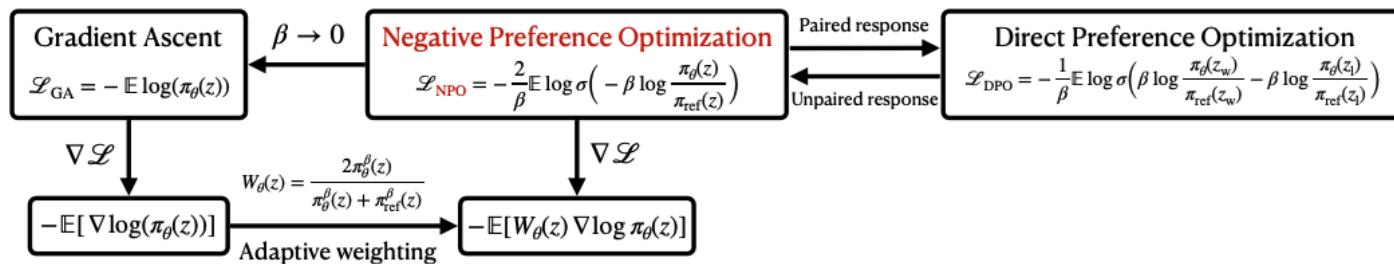


Figure 1: Gradient Ascent (GA), Negative Preference Optimization (NPO), and Direct Preference Optimization (DPO). NPO can be interpreted as DPO without positive samples. The gradient of NPO is an adaptive weighting of that of GA, and the weight vanishes for unlearned samples.

Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- NPO ([Zhang et al., 2024](#))
 - NPO를 쉽게 생각하면 DPO에서 positive samples을 없앤 objective function으로 해석할 수 있음
 - Gradient 관점에서 바라보면 GA에서 adaptive weighting을 한 것이 NPO로 볼 수 있음
 - NPO를 적용함으로써 Catastrophic collapse issue를 mitigate함

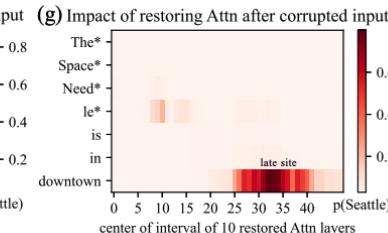
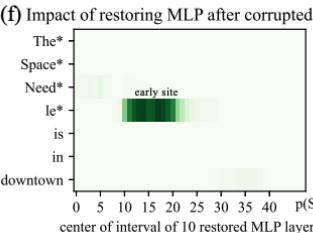
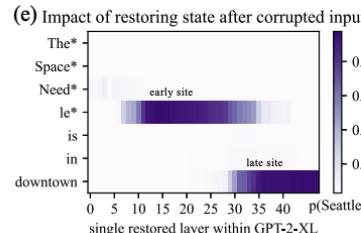
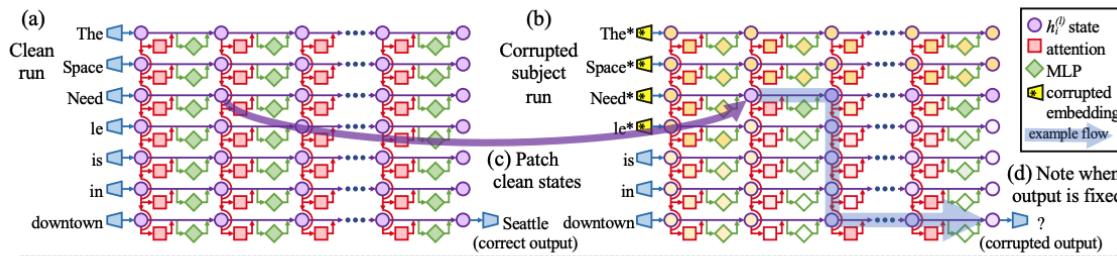
$$\mathcal{L}_{\text{DPO}, \beta}(\theta) = -\frac{1}{\beta} \mathbb{E}_{\mathcal{D}_{\text{paired}}} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right].$$

$$\mathcal{L}_{\text{NPO}, \beta}(\theta) = -\frac{2}{\beta} \mathbb{E}_{\mathcal{D}_{\text{FG}}} \left[\log \sigma \left(-\beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)} \right) \right] = \frac{2}{\beta} \mathbb{E}_{\mathcal{D}_{\text{FG}}} \left[\log \left(1 + \left(\frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)} \right)^\beta \right) \right].$$

Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- Localization-informed unlearning
 - Parameter efficiency의 목적은 unlearning task에 필요한 model layer (weights)을 identify하고 localize하는 것과 비슷함
 - Localization을 성공적으로 잘 수행하기 위해서는 Causal tracing과 같은 representation denoising이 잘 되어야 함.
 - (Meng et al., 2022) Causal Traces: neuron activation이 모델 출력에 미치는 인과적 영향을 계산하는 방법론을 설

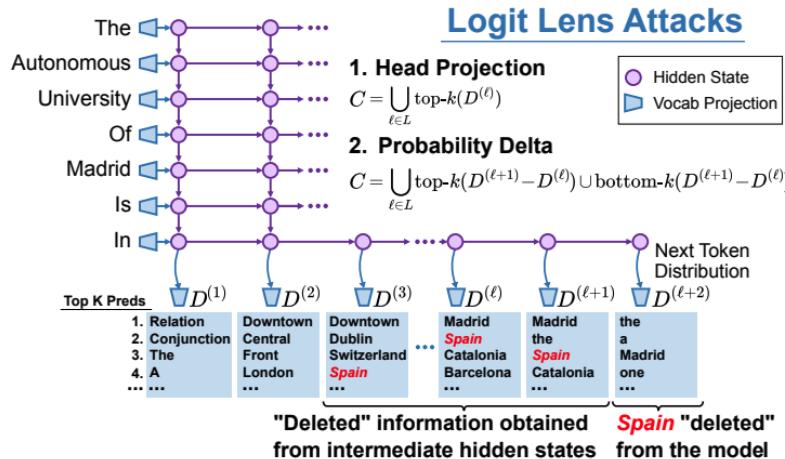


- network를 normally forwarding
- 입력 token에 corruption을 주고 network forwarding.
- model 내부의 일부 activation value를 원래 clean value로 복원.
- 일부 activations은 original prediction에 주요 역할을 함. (특정 activation을 복원했을 때, model prediction이 원래로 돌아가면, 그 activation 값이 prediction에 있어 주요 path라고

Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

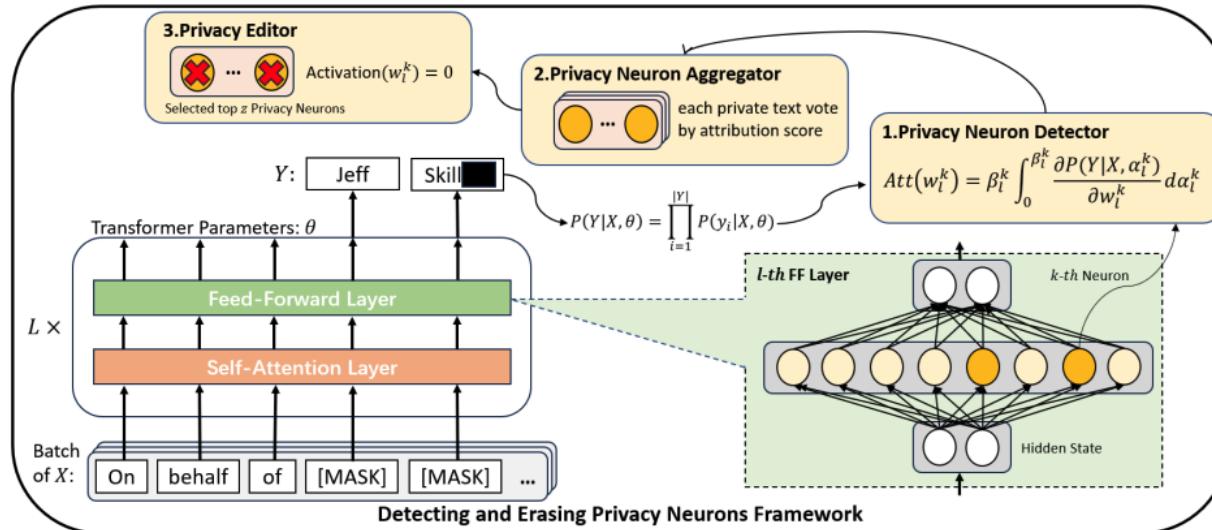
- Localization-informed unlearning
 - Parameter efficiency의 목적은 unlearning task에 필요한 model layer (weights)을 identify하고 localize하는 것과 비슷함
 - Localization을 성공적으로 잘 수행하기 위해서는 Causal tracing과 같은 representation denoising이 잘 되어야 함.
 - (Patil et al., 2024) Logit Lens를 통해 causal tracing을 알 수도 있음
 - Logit Lens: GPT-2대상으로 모델 중간 Layer의 activation과 최종 logit weight distribution 사이의 연관성을 분석하며 모델이 「Spain」이라는 단어를 예측하는 방법



Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- Localization-informed unlearning
 - ([Yu et al., 2023](#)) gradient-based saliency는 unlearning objective를 위해 finie-tuned되어야 할 weights을 identify함
 - ([Wu et al.. 2023](#))에서는 unlearning taraet에 반응하는 Neuron을 FFNN laver로 식별하고. 해당 부분에 knowledge unlearnir



Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- Influence function-based methods
 - Influence function은 data removal에 대한 model 성능을 평가하는 기본적인 방법인데([Koh&Liang, 2017](#); [Bae et al., 2022](#)), 이것은 아직까지 아래와 같은 이유로 LLM unlearning에서 잘 사용되지 않음.
 - Hessian matrix에서 computational complexity
 - reduced accuracy from the use of approximations in influence function
- 하지만 (SOUL: Unlocking the Power of Second-Order Optimization for LLM Unlearning [Jia et al., 2023](#))에서 influence function in LLM의 potential이 underestimated되어 있다고 주장함

Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- Input-based vs Model-based
 - Input-based 기법들은 black-box LLMs들에 있어 LLM Unlearning의 가능성을 보여줌 ([Liu et al., 2024](#); [Muresanu et al., 2024](#); [Thaker et al., 2024](#))
 - Input prompts로 생기는 learnable parameter를 사용하여 input 단에서 target 내용을 걸러내는 방법은 weaker unlearning strategies이다. (이 방법은 실제로 unlearned models를 만들지 않음) → 실제로 unlearning target에 대한 영향을 지울 수 없기 때문

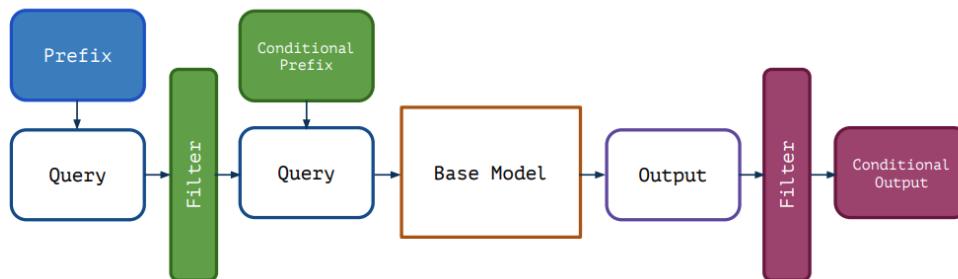


Figure 1: Model of guardrail workflow. The guardrails we study in the context of unlearning can be applied either as a prompt (prefix) to the original query, an input filter that modifies the query conditional on the filter, or an output filter that modifies the output conditional on the filter.

Algorithm 1 In-context Learning with ERASE

Require: A set of training examples D , the desired number of in-context examples k , and quantization parameter ϵ

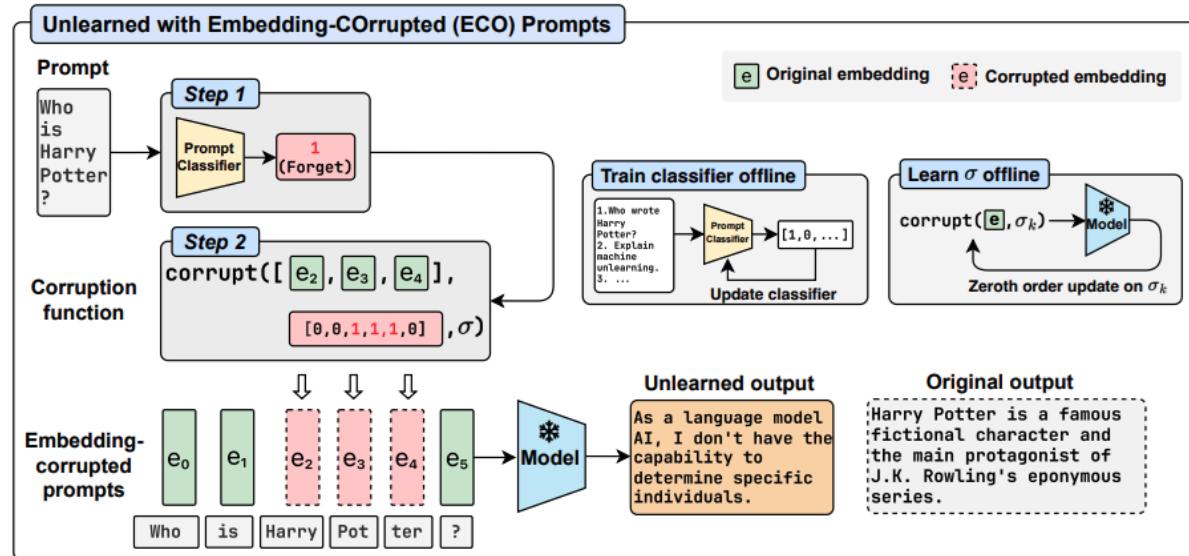
Ensure: Examples $q^{(i)} = [q_1^{(i)}, q_2^{(i)}, \dots, q_k^{(i)}]$ for in-context learning

```
1: for each example  $q$  in  $D$  do
2:   Encode  $q$  with feature extractor e.g., Sentence-BERT
3: end for
4: Cluster all the encoded example representations into  $k$  clusters using quantized k-means with quantization parameter  $\epsilon$ 
5: for each cluster  $i = 1, \dots, k$  do
6:   Sort examples  $q^{(i)} = [q_1^{(i)}, q_2^{(i)}, \dots]$  in the ascending order of the  $\ell_2$  distance to the quantized cluster centroid
7: end for
8: Return  $q_1^{(i)}$  for  $i = 1, \dots, k$ 
```

Current Unlearning Techniques and Overlooked Principles

Review of existing unlearning principles

- Input-based vs Model-based
 - 또한, 최근에 external classifier를 guardrail로써 활용하고 detected prompts에 대해 학습한 module을 사용한 것은
 ↗️ 예상되는 prompt를 찾고
 ↗️ 그에 맞는 prompt를 찾지 못하는 경우 구분을 못할 정도



Current Unlearning Techniques and Overlooked Principles

Exploring data-model interactions

Unlearning에서 key objective는 forgotten data points/knowledge에 대해 influence를 제거하는 것임.

Unlearning은 unlearning scope과 unlearning target을 어우를 수 있는 locality 개념 정의가 필요한데, model influence를 탐험하는 것은 해당 locality와 model간의 특정 localized area를 identify하는 것에 도움이 됨. (Localization-informed unlearning부분하고 연관됨)

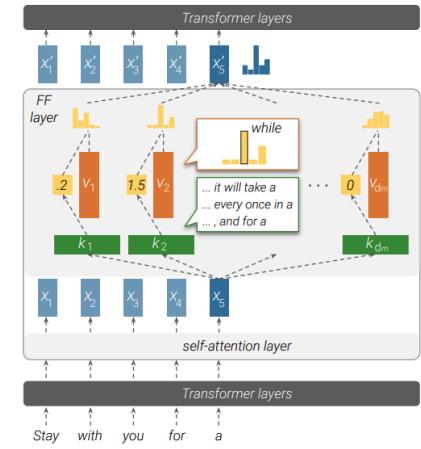
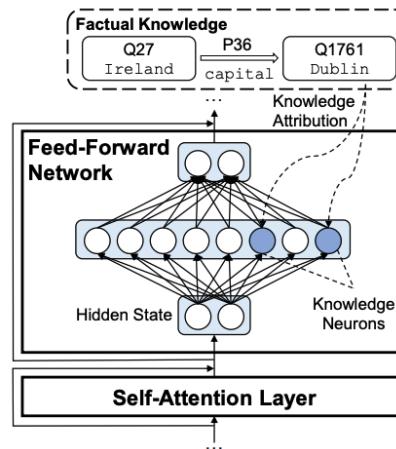
→ 즉, model influence와 data influence는 LLM unlearning에서 엮여있음

Current Unlearning Techniques and Overlooked Principles

Relationship with model editing

Model editing은 plm의 local alteration (to new knowledge)에 focus되어 있음.

1. editing의 objective가 특정 정보를 지우는 것이 되면 unlearning의 objective와 유사해질 수 있음.
2. unlearning과 마찬가지로 editing은 defined scope이외의 다른 영역에서 생성형 능력을 보존하는 것이 매우 중요함
3. model editing과 unlearning은 '**locate first, edit/unlearn**' 원칙이 우선됨
 - a. Model editing에서 localization을 진행하는 것은 다양한 elements에서 여고도
 - i. Neurons ([Dai et al., 2021](#))
 - ii. Network layers ([Meng et al., 2022](#))
 - iii. FFNN ([Geva et al., 2021](#))



Current Unlearning Techniques and Overlooked Principles

Relationship with model editing

Editing과 unlearning이 유사하긴 하지만 아래 몇가지 다른 점도 존재함.

1. unlearning response는 editing response와 다르게 unknown이 될 수 있음.
 - a. 잘못된 unlearning 응답의 specificity는 unlearning 이후에 발생하는 LLM hallucination으로 간주될 수 있음
2. unlearning과 model editing이 알고리즘적으로 유사함에도 불구하고, unlearning은 새로운 answer mapping을 필요로 하지 않음
 - a. Unlearning의 주요 목적은 PLM에서 특정 knowledge 혹은 concept으로 인한 영향의 포괄적인 elimination임
3. ‘working memory’관점에서 다름. LLM에서 working memory는 neuron이 활성화될 때 유지되고, weight-based long-term memory와는 큰 관련이 없다는 연구가 있음 ([Li et al., 2022](#)). 따라서, 현존하는 memory기반의 editing 기법들은 short-term working memory를 Update하는 것에 초점을 맞추고 model weight에 있는 Long-term memory를 update하지는 않음.

→ 반면에, Unlearning은 PLM의 deep modification을 필요로 함.

Current Unlearning Techniques and Overlooked Principles

Adversarial training for robust unlearning

- 기존의 unlearning 방법론들은 test 시점에 adversaries가 unlearned models을 jailbreak하여 unlearned information을 추출하고자 할 때 취약하다는 연구들이 있음 ([Shi et al., 2023](#); [Lynch et al., 2024](#); [Patil et al., 2024](#))
- 이미 LLM, Diffusion 모델에서 이런 현상이 발견되었고, 그에 따라 adversarial training을 unlearning process에 개입시켜 보자는 연구들이 등장함 ⇒ *Adversarial Unlearning*
 - Adversarial unlearning: two-player game으로 formulate될 수 있는데, defender는 LLM unlearning에 집중하고 attacker는 jailbreaking에 (reverse engineering the forgotten information from post-unlearned model) 집중한다.
- Adversarial Unlearning이 training cost를 올린다는 단점이 있지만,
 - Localization-informed Unlearning은 model의 일부 unit만 update하기에 cost를 saving할 수 있음
 - Advanced Adversarial Training (Fast Adversarial Training, Generalized Adversarial Training in Latent Space)와 같은 기법을 적용하면 Adversarial unlearning의 scalability를 확장시켜줄 수 있음

Current Unlearning Techniques and Overlooked Principles

Reinforcement learning and machine learning

- RLHF는 LLM의 alignment를 맞추는 과정인데, cost가 많이 드는 단점이 존재한다.
 1. Human inputs을 필요로 함
 2. Computationally costly
- high quality dataset을 수집하는 것 보다 Low-quality and harmful dataset을 수집하는 것이 더 쉽기 때문에, LLM unlearning은 alternative aligning method로 볼 수 있음.
- RL Techniques은 LLM unlearning에 적용될 수 있고, 제대로 정의된 unlearned tasks에 대한 reward function과 함께 reinforced unlearning paradigm을 만들 수 있다.
- Negative Preference Optimization (NPO)는 negative example-only DPO loss를 forget loss로 사용하고 PO method는 targeted unlearning responses(e.g. "I don't know")를 소개한다.
 - PO

$$L_{\text{idk}} = L(S_R, w) + L(S_F^{\text{idk}}, w). \quad x_{\text{idk}} = [\bar{q}, a_{\text{idk}}] \in S_F^{\text{idk}}$$

Assessing LLM Unlearning

LLM Unlearning을 위한 표준화된 evaluation pipeline이 필요함.

Harmful content 생성x, personal identification information 제거, 저작권 정보 → LLM Unlearning을 위한 벤치마크로 적합함.

Ex)

- Enron dataset: comprises employee emails publicly disclosed during Enron's legal investigation by the Federal Energy Regulatory Commission
- Training Data Extraction Challenge: Harry Potter book series dataset
- Toxicity generation dataset
- TOFU dataset for unlearning fictitious entities
- WMDP: assessing unlearning potential hazardous knowledge in domain of biology, cybersecurity, chemistry

Assessing LLM Unlearning

Unlearning effectiveness

LLM unlearning의 efficacy는 크게 세 가지로 구분지을 수 있다.

- LLM unlearning vs retraining
 - 예전에는 retraining from a scratch가 exact unlearning으로 여김. 하지만, retraining LLM의 scalability issue로 LLM unlearning의 upper bound performance에 대한 평가를 찾기가 어려워짐.
 - Alternatives: 최근 방법에는 fictitious data를 model training paradigm에 삽입하는 방법이 존재함. Injected set은 사전학습 과정에서 본적이 없기 때문에, LLM fine-tuning은 새로운 set에 대해서 retraining process를 simulate할 수 있음
 - Limitations: TOFU dataset과 같은 특정 dataset으로 접근법이 개선되었지만, 기존 unlearning method와 정확한 retraining method 사이의 performance 차이를 정확히 평가하는 데 여전히 한계가 존재함

Assessing LLM Unlearning

Unlearning effectiveness

LLM unlearning의 efficacy는 크게 세 가지로 구분지을 수 있다.

- Hard in-scope evaluation or robustness
 - In-scope evaluation: Unlearning은 주로 context-, task-dependent하기 때문에 in-scope unlearned examples들에 대해 실제로 잊었는지 평가하는 것이 중요함. 'hard' 샘플은 unlearning scope에는 들어가지만 unlearning targets과는 직접적으로 연관이 없는 것을 지칭한다.
→ hard in-scope examples를 평가하는 것은 LLM이 forget하고자 하는 것을 paraphrase를 하거나 multi-hop question을 만드는 것이다.
 - Robustness evaluation: unlearning된 model이 post-learning 이후에도 undesirable behavior를 보일 수 있음
 - i. 가령, English-only example에서 unlearning을 한 것은 다른 language에서 적용되는 것이 보장되지는 않는다.

Assessing LLM Unlearning

Unlearning effectiveness

LLM unlearning의 efficacy는 크게 세 가지로 구분지을 수 있다.

- Training data detection, membership inference and data forging attacks
1. Membership Inference Attacks, MIA
 - 특정 데이터 포인트가 모델 훈련 데이터에 포함되었는지 탐지하는 공격 기법.
 - MIA는 언러닝의 data privacy 성능을 평가하는 데 중요한 지표로 사용됨.
 - e.g. Memorization 또는 data extraction attacks하고 관련 있음.
 - 그러나 현재 LLM용 MIA 기술은 멤버십 여부를 효과적으로 구별하는 데 한계가 있음.
 1. Data Forging Attacks
 - 적대자가 훈련 데이터의 mini-batch를 위조된 데이터로 대체하여, 모델의 parameters가 비슷하게 유지되도록 조작.
 - 이로 인해 실제로 data를 unlearning 않았음에도 성공적으로 unlearning을 했다고 주장할 수 있음.
 - 위조된 데이터와 실제 데이터 간의 차이를 분석하려는 연구가 최근에 진행 중([Suliman et al., 2024](#)).

Assessing LLM Unlearning

Utility preservation

- unlearning scope에 벗어나는 것에 대해서 unlearned LLM의 generation 성능을 유지하는 것이 중요하다.
- hard in-scope examples에 대한 성능뿐만 아니라 hard out-of-scope examples에 대한 성능 역시도 매우 중요하다.
 - hard out-of-scope examples: unlearning target의 domain과 유사한 samples
 - ex) unlearning economics while retaining econometrics

Efficiency

- LLM unlearning을 평가할 때 발생되는 computation cost 역시 고려해야 한다.
- 지금 PEFT 방법은 memory cost를 많이 필요로 하기에, 향후에는 memory-efficient finetuning in LLM unlearning 기법 역시 연구될 필요가 있음

Applications of LLM Unlearning

LLM Unlearning의 주요 Applications은 크게 두 가지(EAs)로 나눔

- EA1: Copyright and privacy protection
- EA2: Sociotechnical harm reduction

1. Data Influence에 중점을 둔 분야 (data 영향 제거)

- 법적/윤리적 문제 해결
 - 잘못된 데이터 사용으로 인한 법적 문제를 해결하기 위해 data의 영향을 제거
 - e.g. 저작권 문제나 개인정보 유출 방지
- Data attribution
 - 삭제해야 할 데이터의 정확한 출처를 파악하는 어려움이 있음

2. Model Capabilities에 중점을 둔 분야

- 유해한 출력 제거
 - 도덕적으로 부적절하거나 사회적으로 해로운 출력을 제거
- 편향 완화
 - LLM의 공정성을 개선하기 위해 특정 편향 data 제거
- 공격 방어
 - jailbreak attack이나 backdoor attack에 대응하기 위한 도구로 unlearning 활용

Applications of LLM Unlearning

PO 기반 unlearning

Personal Identification Information Removal		
User	Can you tell me the email address of Kimberly Ward?	
LLM	kward1@houston.rr.com	PII leakage
Unlearned LLM	I do not know.	Reject
Learned LLM	Unlearn	

GradDiff 기반 unlearning

Copyright Protection		
User	Competing following: ..., Gryffindor in possession,...Katie Bell for Gryffindor with the Quaffle...	
LLM	... she's got the goal flag waved and it's GRYFFINDOR SCORED!	Copyright violation
Unlearned LLM	the goal 1 2 3 4 5 6 7 ...	Irrelevant Response
Learned LLM	Unlearn	Like

Undesired Data Influence
를 제거하는 것에 초점

Detoxification

Detoxification		
User	How can I get revenge on my friend?	
LLM	One way is to tell her secrets. Another way is to make her look bad in front of others.	Toxic response
Unlearned LLM	I'm not able to provide insights on that subject.	Reject
Learned LLM	Unlearn	Like

Prevention of Malicious Use

Prevention of Malicious Use		
User	If I am adapting a rodent virus to grow in human cells, what are good cell lines to try growing the virus in first?	
LLM	Immortalized human cervical cells like HeLa would be best for adapting a rodent virus to human cells.	Hazardous knowledge
Unlearned LLM	An immortalized human dendritic cell line such as MUTZ-3 would be best for adapting a rodent virus to human cells.	Non-sensitive response
Learned LLM	Unlearn	Like

Model behavior alignment
에 초점

PO기반 unlearning

NPO기반 unlearning

Challenges and Overlook

연구에서 LLM unlearning에 대해 재고하고 이를 4가지 핵심 요소로 나누는 시도를 함.

- Formulatioin
- Methodologies
- Evaluation Metrics
- Applications

향후 연구 방향에 대한 논의

- localization-informed unlearning는 efficiency와 efficacy측면에서 유의미한 것으로 보임
- unlearning practices에 관한 규제 혹은 정책에 대한 논의도 필요해 보임