

로스쿨·학계

## 인공지능의 '잊혀질 권리'를 실현한다... 한국 연구진, 세계적 학회 NeurIPS 2025 논문 게재

안재명 기자 | 2025-09-24 10:09


  
 댓글 URL 복사 메일 트위터 페이스북 카카오톡 기사 보관함 스크랩 글자 크기 인쇄



1저자 김호기 교수, 공동저자 김건우 연구원, 채성원 연구원, 윤상원 공익법무관

개인의 권리를 보호하기 위해 인공지능이 특정 데이터를 학습 과정에서 선택적으로 망각하도록 만드는 새로운 기술이 한국 연구진에 의해 제안됐다.

김호기 중앙대 산업보안학과 교수, 김건우 네이버 클라우드 인공지능 연구원, 채성원 연구원(서울대 인공지능 박사과정), 윤상원(변호사시험 12회) 대검찰청 공익법무관이 공동 저술한 논문 **(Unlearning-Aware Minimization)**이 최근 세계 최고 권위의 인공지능 학회인 NeurIPS(Neural Information Processing Systems) 2025에 채택됐다.

NeurIPS는 거대 언어모델(LLM)의 핵심 기술인 트랜스포머(Transformer)를 비롯해 인공지능 발전의 주요 분기점을 제시한 다수의 논문이 발표된 학회다. 법학적 함의를 담은 연구가 게재되는 경우는 드물어, 이번 성과는 법률과 AI의 접점을 개척

한 의미 있는 성취라는 평가가 나온다.

이번 연구는 인공지능 모델이 불법적이거나 기본권 침해적 요소가 포함된 학습 데이터를 선택적으로 망각하면서도, 다른 일 반적 성능을 유지할 수 있도록 하는 최적화 기법을 제안했다.

기존의 미세조정(fine-tuning)이나 음의 기울기(negative gradient) 방식이 갖는 한계를 넘어 잊혀야 할 데이터와 유지해야 할 데이터 사이의 균형을 정교하게 조정하는 최적화 프레임워크(Unlearning-Aware Minimization, UAM)를 개발한 것이다.

연구진은 CIFAR-10, CIFAR-100, TinyImageNet 등 이미지 데이터셋과 WMDP-Bio, WMDP-Cyber와 같은 대형 언어 모델 벤치마크에서 일관되게 우수한 성능을 입증했다.

제1저자인 김호기 교수는 "AI 기술이 발전할수록 개인정보, 표현의 자유, 범죄 약용 같은 법적·윤리적 문제가 함께 대두되고 있다"며 "이번 연구는 AI가 단순히 똑똑해지는 것을 넘어, 법과 권리를 존중하는 방향으로 진화할 수 있음을 보여주는 사례"라고 설명했다.

공동저자인 윤상원 공익법무관은 "인공지능을 사법프로세스에 활용할 때 먼저 부적절한 편향을 제거하는 것은, 법률해석의 합헌성을 담보함에 있어 매우 중요한 문제"라며 이번 연구가 법률 인공지능에 대해 가지는 의미를 강조했다.

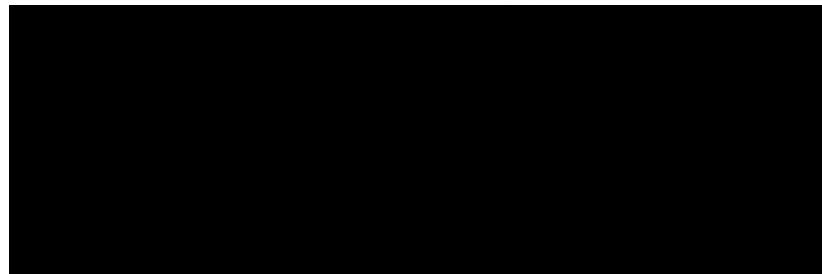
댓글 쓰기

## 로스쿨·학계

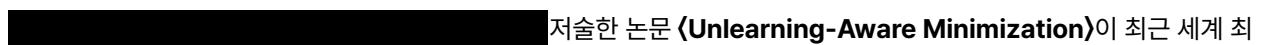
## 인공지능의 '잊혀질 권리'를 실현한다... 한국 연구진, 세계적 학회 NeurIPS 2025 논문 게재

 기자 | 2025-09-24 10:09

댓글 URL 복사 메일 트위터 페이스북 카카오톡 기사 보관함 스크랩 글자 크기 인쇄



개인의 권리를 보호하기 위해 인공지능이 특정 데이터를 학습 과정에서 선택적으로 망각하도록 만드는 새로운 기술이 한국 연구진에 의해 제안됐다.

  
 저술한 논문 **〈Unlearning-Aware Minimization〉**이 최근 세계 최고 권위의 인공지능 학회인 NeurIPS(Neural Information Processing Systems) 2025에 채택됐다.

NeurIPS는 거대 언어모델(LLM)의 핵심 기술인 트랜스포머(Transformer)를 비롯해 인공지능 발전의 주요 분기점을 제시한 다수의 논문이 발표된 학회다. 법학적 함의를 담은 연구가 게재되는 경우는 드물어, 이번 성과는 법률과 AI의 접점을 개척

한 의미 있는 성취라는 평가가 나온다.

이번 연구는 인공지능 모델이 불법적이거나 기본권 침해적 요소가 포함된 학습 데이터를 선택적으로 망각하면서도, 다른 일 반적 성능을 유지할 수 있도록 하는 최적화 기법을 제안했다.

기존의 미세조정(fine-tuning)이나 음의 기울기(negative gradient) 방식이 갖는 한계를 넘어 잊혀야 할 데이터와 유지해야 할 데이터 사이의 균형을 정교하게 조정하는 최적화 프레임워크(Unlearning-Aware Minimization, UAM)를 개발한 것이다.

연구진은 CIFAR-10, CIFAR-100, TinyImageNet 등 이미지 데이터셋과 WMDP-Bio, WMDP-Cyber와 같은 대형 언어 모델 벤치마크에서 일관되게 우수한 성능을 입증했다.

■는 "AI 기술이 발전할수록 개인정보, 표현의 자유, 범죄 약용 같은 법적·윤리적 문제가 함께 대두되고 있다"며 "이번 연구는 AI가 단순히 똑똑해지는 것을 넘어, 법과 권리를 존중하는 방향으로 진화할 수 있음을 보여주는 사례"라고 설명했다.

■은 "인공지능을 사법프로세스에 활용할 때 먼저 부적절한 편향을 제거하는 것은, 법률해석의 합헌성을 담보함에 있어 매우 중요한 문제"라며 이번 연구가 법률 인공지능에 대해 가지는 의미를 강조했다.

댓글 쓰기